

Visão Computacional Aplicada Para Detecção de Placas de Automóveis: Uma Abordagem Utilizando YOLO

Bruno Pontes Duarte
PUC Minas

Belo Horizonte, Brasil
bruno.pduarte0@gmail.com

Caio Elias Rodrigues Araújo
PUC Minas

Belo Horizonte, Brasil
caioelias029@gmail.com

Juliana Serra Camargo Gomes
PUC Minas

Belo Horizonte, Brasil
juserrac03@gmail.com

Letícia de Assis Fraga
PUC Minas

Belo Horizonte, Brasil
lafraga@sga.pucminas.br

Samuel Marques Souza Leal
PUC Minas

Belo Horizonte, Brasil
samuelmarquessouzaleal@gmail.com

Abstract—Vehicle access control is an increasingly important requirement in environments such as residential condominiums, companies, and public buildings. In this work, we propose an intelligent system based on computer vision and deep learning to identify vehicle license plates and automatically verify entry authorization. Using the YOLO 11 model, trained with a custom dataset containing polygon-based annotations, and the EasyOCR model for character extraction, the system is capable of performing real-time detection and accurately validating access. Tests conducted with different vehicles demonstrated the effectiveness of the proposed solution in correctly identifying license plates and allowing or denying access based on an authorized list. The results indicate the feasibility of applying this approach in real-world vehicle security and access control systems.

Abstract—O controle de acesso veicular é uma necessidade crescente em ambientes como condomínios, empresas e prédios públicos. Neste trabalho, propomos um sistema inteligente baseado em visão computacional e aprendizado profundo para identificar placas de veículos e verificar automaticamente a autorização de entrada. Utilizando o modelo YOLO 11, treinado com um conjunto de dados específico contendo anotações por polígonos, e o modelo EasyOCR para extração dos caracteres da placa, o sistema é capaz de realizar detecção em tempo real e validar o acesso com precisão. Os testes realizados com diferentes veículos demonstraram a eficácia da solução proposta em identificar corretamente placas e permitir ou negar o acesso com base em uma lista autorizada. Os resultados indicam a viabilidade da aplicação da abordagem em sistemas reais de segurança e controle de fluxo veicular.

Index Terms—Vehicle Access Control, License Plate Recognition, YOLO, Computer Vision, Deep Learning, EasyOCR.

I. INTRODUÇÃO

O controle de acesso veicular é um componente fundamental para a segurança e organização em diversos ambientes, como condomínios residenciais, empresas e instituições públicas [1]. Tradicionalmente, esse controle é realizado por meio de processos manuais, envolvendo a conferência visual de placas por operadores humanos, o que pode resultar em

erros, atrasos e vulnerabilidades na segurança. Com o avanço das tecnologias de visão computacional e inteligência artificial, tornou-se possível automatizar essa tarefa, aumentando a eficiência e a confiabilidade dos sistemas de controle.

Neste contexto, a detecção automática de placas de veículos (ALPR - *Automatic License Plate Recognition*) vem ganhando destaque como uma solução tecnológica capaz de substituir métodos convencionais [2]. A arquitetura YOLO (*You Only Look Once*) representa um avanço significativo na detecção em tempo real, combinando alta precisão com velocidade de processamento adequada para aplicações em ambientes dinâmicos. Aliada a técnicas de OCR (*Optical Character Recognition*), que permitem a extração precisa dos caracteres das placas, essa combinação possibilita o desenvolvimento de sistemas de controle de acesso totalmente automatizados.

Este trabalho explora a viabilidade de um sistema baseado na arquitetura YOLO 11 para a detecção eficiente das placas veiculares, juntamente com OCR para o reconhecimento dos caracteres, aplicando-os no contexto do controle de acesso. Além da implementação e validação do modelo, busca-se avaliar sua performance em condições realistas, visando a substituição de processos manuais, redução de erros humanos e melhoria da segurança. O estudo também aborda as limitações atuais e propõe direções para futuras melhorias, como a integração com câmeras de *streaming* ao vivo, ampliação do dataset para cobrir diferentes condições ambientais e a adaptação para múltiplos tipos de placas.

II. MÉTODO

A. Dataset

O conjunto de dados utilizado neste estudo foi obtido a partir da plataforma *Roboflow* [3], consistindo em 643 imagens de 640x640 px de placas de veículos brasileiras no modelo antigo. Esse conjunto foi organizado em duas partições: *train/* e *valid/*, correspondentes às fases de treinamento e validação do modelo YOLO, respectivamente. Cada imagem presente

nas pastas é acompanhada de um arquivo de anotação que indica a posição da placa veicular na cena.

Diferentemente do formato tradicional de anotações com *bounding boxes* (caixas retangulares), o dataset adotou um formato mais avançado, compatível com as versões mais recentes do YOLO, que permite a utilização de polígonos com quatro pontos para demarcar a área de interesse — neste caso, a placa do veículo. Essa abordagem oferece maior precisão na detecção, especialmente em cenários em que as placas aparecem inclinadas, parcialmente obstruídas ou com perspectiva distorcida.

As coordenadas dos pontos anotados foram normalizadas para o intervalo de 0 a 1, conforme o padrão esperado pelo modelo YOLO 11. Essa normalização garante que o modelo possa generalizar sua capacidade de detecção independentemente da resolução das imagens, promovendo maior robustez durante o treinamento e a inferência. A curadoria do dataset e a escolha pelo uso de anotações poligonais foram fatores determinantes para a melhoria da acurácia do modelo em cenários reais de monitoramento veicular.

B. Modelo YOLO 11

O modelo de detecção escolhido para este trabalho foi o **YOLO** (*You Only Look Once*), uma das mais recentes e avançadas arquiteturas de detecção de objetos em tempo real. O YOLO 11 apresenta melhorias significativas em relação às versões anteriores, incluindo suporte a segmentação, detecção de keypoints, melhor gerenciamento de anotações com polígonos e uma estrutura otimizada para execução em dispositivos com diferentes capacidades computacionais.

Por padrão, o modelo YOLO é pré-treinado com conjuntos de dados amplos, sendo capaz de identificar classes genéricas como pessoas, carros, bicicletas, entre outras. No entanto, para a detecção de placas veiculares — uma tarefa mais específica e que não está contemplada diretamente nesses datasets genéricos — foi necessário realizar um *fine-tuning* do modelo com um conjunto de dados customizado, conforme descrito anteriormente.

A combinação das métricas **box_loss** e **cls_loss**, descritas a seguir, forneceu uma visão da performance do modelo durante o treinamento. Com base nesses indicadores, foram realizadas iterações para ajuste dos hiperparâmetros taxa de aprendizagem e número de épocas, até que o modelo alcançasse um desempenho satisfatório para sua aplicação em tempo real.

- **box_loss**: mede a precisão da predição das caixas delimitadoras (*bounding boxes*);
- **cls_loss**: avalia a acurácia na classificação das classes detectadas;

Após a identificação da placa, a área delimitada é cortada da imagem inicial e é salva para uso posterior.

C. OCR e Verificação de Acesso

Após a detecção das placas veiculares por meio do modelo YOLO, a próxima etapa do processo envolve a extração e

TABLE I
CARACTERES ALFANUMÉRICOS VISUALMENTE SEMELHANTES

Letra	Número
B	8
G	6
I	1
O	0
S	5
Z	2

interpretação do conteúdo textual presente nas regiões detectadas. Para isso, foi utilizado o modelo **EasyOCR**, uma ferramenta de reconhecimento óptico de caracteres (OCR) baseada em redes neurais profundas, conhecida por sua capacidade de interpretar textos em diferentes condições de iluminação, ângulos e qualidade de imagem.

O EasyOCR atua sobre a região da imagem delimitada pela detecção do YOLO, processando e retornando uma string contendo os caracteres alfanuméricos reconhecidos na placa. Essa string é então submetida a um processo de normalização, essencial devido ao padrão das placas brasileiras, que seguem a estrutura de três letras seguidas por quatro números. Essa etapa tem como objetivo reduzir ambiguidades causadas por caracteres visualmente semelhantes, descritos na Tabela I, como “G” e “6”, com base na posição que cada caractere ocupa na placa.

Após a normalização, a string resultante é comparada com uma lista previamente definida de placas autorizadas a acessar o ambiente monitorado. Com base nessa verificação, o sistema decide automaticamente se o acesso do veículo deve ser concedido ou negado. Essa etapa é essencial para garantir a integridade do controle de entrada e saída, substituindo o julgamento humano por uma decisão automatizada, rápida e rastreável. Além disso, toda a cadeia de decisões pode ser registrada para fins de auditoria e segurança, oferecendo um sistema robusto para aplicações reais em portarias automatizadas de condomínios, empresas e instituições públicas.

III. EXECUÇÃO

Com o modelo YOLO 11 treinado e validado, o sistema foi configurado para realizar testes práticos com imagens reais de veículos. A execução consiste nas seguintes etapas: seleção da imagem de entrada, aplicação do modelo YOLO para detecção da placa veicular, extração dos caracteres com EasyOCR e, por fim, verificação da autorização de acesso.

Para este experimento, foram utilizadas imagens de dois veículos distintos. No primeiro teste, uma imagem de um carro amarelo foi submetida ao sistema. O modelo YOLO identificou corretamente a placa na imagem, destacando visualmente a região com uma caixa delimitadora e fornecendo um valor de confiança elevado. O EasyOCR então extraiu os caracteres da placa detectada. Após normalização dos dados, o sistema comparou o valor reconhecido com uma lista de placas autorizadas e, como o veículo não constava na base de dados, o acesso foi negado.

No segundo teste, uma imagem de um carro azul foi processada. O sistema seguiu os mesmos passos de detecção,

extração de texto e verificação. Neste caso, a placa do veículo constava na lista de autorização e o sistema automaticamente sinalizou que o acesso estava permitido.

Durante ambos os testes, o sistema demonstrou precisão na localização da placa e confiabilidade na leitura dos caracteres. A interface de execução permitiu acompanhar visualmente o processo, com destaque para as regiões identificadas e mensagens indicando o status do acesso (permitido ou negado). Essa etapa prática valida a capacidade do sistema de operar em cenários reais de controle de acesso veicular com base em imagens estáticas.

IV. RESULTADOS

Os testes realizados com o sistema proposto demonstraram resultados positivos em termos de precisão e eficiência. O modelo YOLO 11, treinado com o conjunto de dados anotado por polígonos, foi capaz de identificar placas veiculares com alta confiança, mesmo em imagens com inclinação, variações de luminosidade e ruídos visuais. A utilização de anotações por polígonos foi fundamental para lidar com placas inclinadas e aumentar a acurácia da detecção.

O modelo obteve valores baixos de perda (*loss*) durante o treinamento: a *box_loss* indicou boa capacidade de localização das placas; a *cls_loss* demonstrou precisão na classificação; e a *dfl_loss* confirmou o bom desempenho na regressão das caixas. A métrica *mean Average Precision* (mAP) foi satisfatória, evidenciando o desempenho geral adequado para uso prático.

Além da detecção, o modelo EasyOCR se mostrou eficiente na extração de texto, mesmo em imagens de baixa resolução. A verificação de acesso funcionou corretamente nos testes, permitindo ou negando a entrada com base em uma lista pré-definida de placas. O tempo total de resposta do sistema, desde a leitura da imagem até a decisão de acesso, foi curto, o que reforça o potencial de aplicação em tempo real.

Esses resultados indicam que a abordagem proposta é viável para integrar sistemas automatizados de controle de acesso veicular, contribuindo para a segurança, agilidade e rastreabilidade em ambientes restritos.

V. CONCLUSÃO

Este trabalho comprovou a eficácia de um sistema automatizado para controle de acesso veicular, baseado na arquitetura avançada YOLO combinada com técnicas de OCR para leitura de placas. A integração dessas tecnologias resultou em uma solução robusta e precisa para a detecção e identificação das placas, garantindo a verificação confiável da autorização de veículos.

Os resultados experimentais indicam que o sistema pode ser implementado em ambientes reais, como condomínios residenciais, empresas e instituições públicas, oferecendo uma alternativa automatizada que reduz significativamente a dependência de processos manuais e os erros humanos associados. Para aprimorar a aplicabilidade prática do sistema, trabalhos futuros incluem a integração com câmeras em tempo real (*streaming*), o enriquecimento do dataset com imagens em diferentes condições ambientais, como períodos diurnos,

noturnos e sob chuva, além da adaptação para reconhecer múltiplos padrões de placas veiculares existentes.

REFERENCES

- [1] Chang, S. L., Chen, L. S., Chung, Y. C., & Chen, S. W. (2004). Automatic license plate recognition. *IEEE transactions on intelligent transportation systems*, 5(1), 42-53.
- [2] Gonçalves, G. R., da Silva, S. P. G., Menotti, D., & Schwartz, W. R. (2016). Benchmark for license plate character segmentation. *Journal of Electronic Imaging*, 25(5), 053034-053034.
- [3] Placa de carro Dataset, Roboflow Universe, Roboflow, Aug. 2024. [Online]. Acessado em: maio 2025. Available: <https://universe.roboflow.com/trabalho-jnal6/placa-de-carro-oz0eg>